DMQA 인턴 미팅

<생육 분석 자동화 Vision AI 모델 개발>

불확실성과 시계열 모델링 기반 작물 생육일자 예측

2024. 12. 26

민찬홍

Korea University

Data Mining & Quality Analytics Lab.

Data Mining Quality Analytics CJ 제일제당

목차

- 1. 불확실성
- 2. 불확실성 실험 결과
- 3. 시계열 모델링
- 4. 시계열 모델링 실험 결과
- 5. 결론
- 6. 인턴 생활 후기

1. 불확실성

1. Uncertainty

1. 불확실성

❖ Uncertainty 확인하는 이유

- Neural Net들은 단지 학습 데이터에 fitting 되어있는 상태에서 사용
- 따라서, 학습 데이터에서 보지 못한 예측 데이터에 대해 Neural Net이 정확하게 예측하는지 의문을 가질 필요성 존재 ->Uncertainty 정량화!
- Uncertainty: 모델의 예측 결과를 얼마나 신뢰할 수 있는지 나타내는 지표

❖ Uncertainty 정량화 방법: MC Dropout

- Bayesian 기반 modeling: 여러 개의 Output들의 분포에서 나오는 표준편차를 활용
- MC Dropout: inference 시 dropout 활성화시켜 여러 번의 output 뽑음

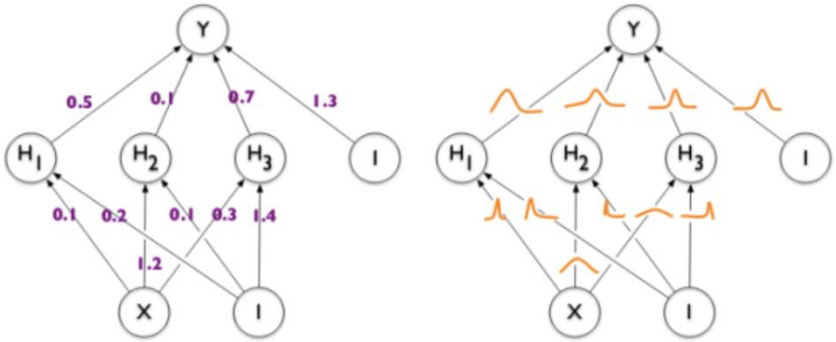

1. 불확실성

❖ Dropout 적용

- 표준편차를 통해 불확실성 정량화 (inference 할 때만 dropout 적용)

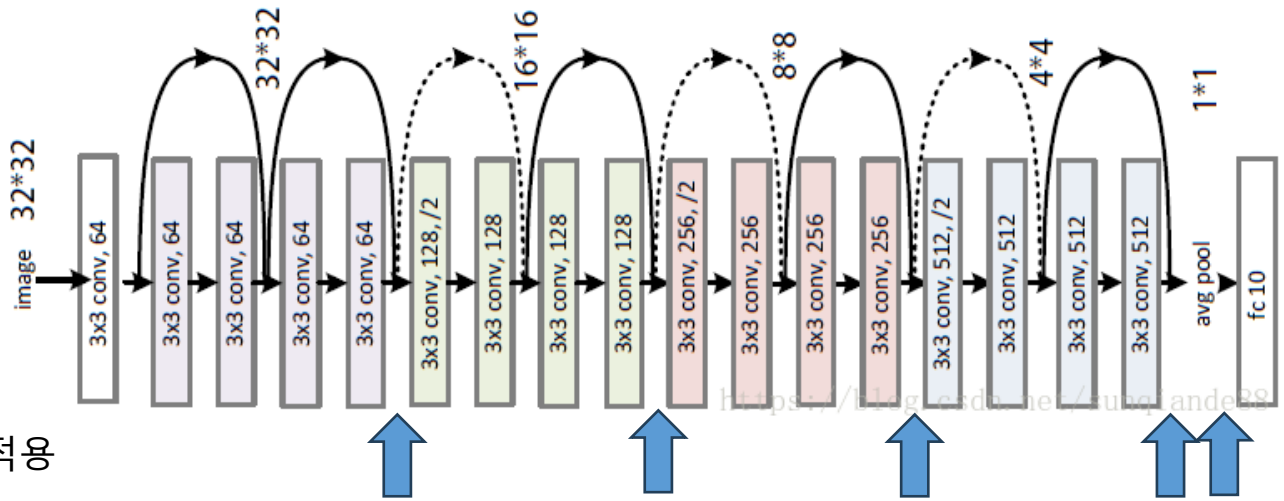

Dropout 적용

❖ Dropout 적용 위치

- ResNet의 각 계층(layer1 ~ layer4)은 각기 다른 수준 특징 학습한다는 특성 반영
- ResNet의 shortcut 연결에는 영향을 주지 않으므로, 입력 x의 정보 손실 위험 방지

2. 불확실성 실험 결과

❖ Dropout Rate

- 휴리스틱한 방법으로 시도(10^{-1}~10^{-5})
- Dropout rate가 커질수록 Uncertainty 값이 증가함

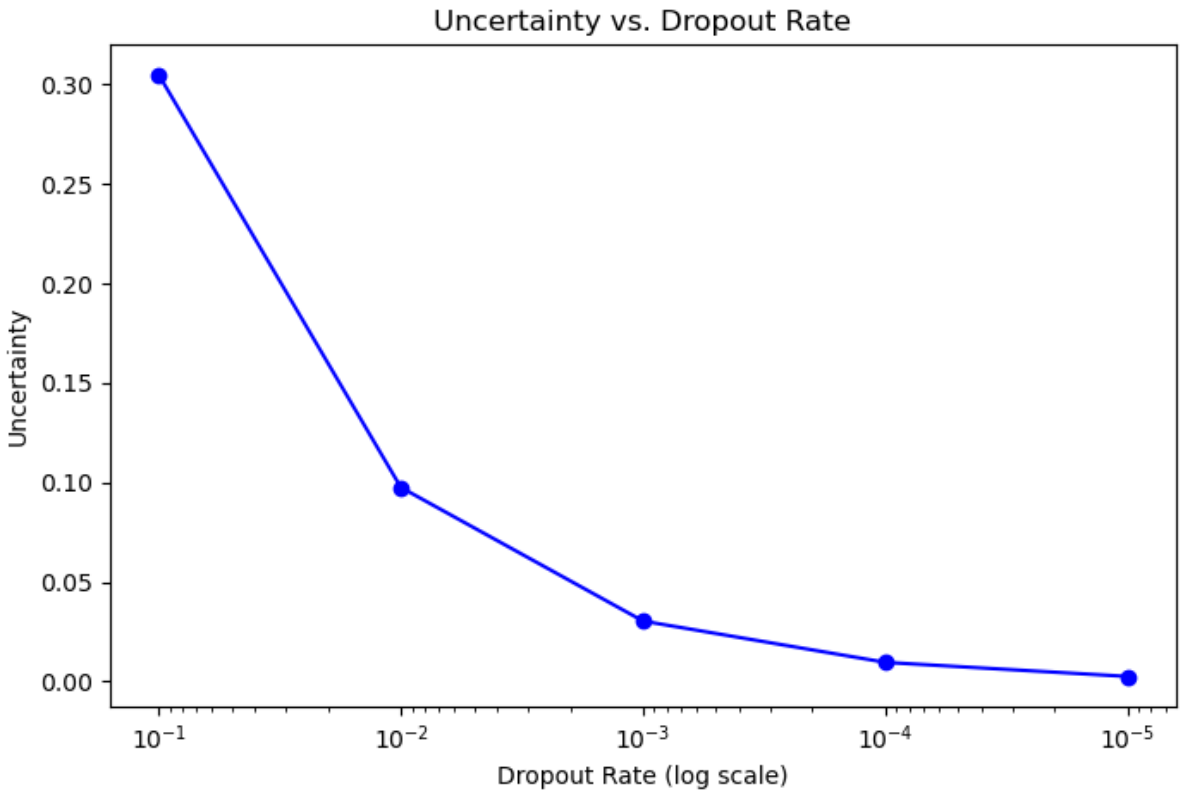

2. 불확실성 실험 결과

❖ Dropout Rate

- Dropout rate에 따른 Uncertainty, MAE 산출
- Dropout rate가 증가함에 따라 MAE는 감소함
- 모델이 학습 data 과적합 되었기 때문이라고 판단

	기존 모델	10e-1	10e-2	10e-3	10e-4	10e-5
Uncertainty (Std.)	/	0.305	0.098	0.030	0.010	0.002
MAE	1.046	0.861	1.026	1.045	1.047	1.046

2. 시계열 모델링

2. 시계열 모델링

3. 시계열 모델링

❖ **과거 정보 함께 활용 → 작물의 시계열적 성장 과정 반영 → 생육 지표 예측 성능 향상**

- 단일 시점이 아닌, **과거 시점 정보까지 함께 반영하여 모델링**

AS-IS

단일 시점 이미지만을 고려하여 모델링

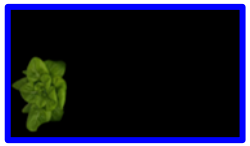

154g

TO-BE

과거 시점 이미지를 함께 활용하여 모델링

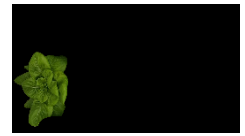

3일차 19시

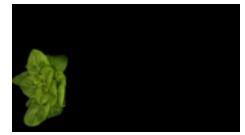

4일차 08시

4일차 19시

154g

3. 시계열 모델링

❖ 실험 1. 학습 data 모두 사용

- **기존 방법론보다 성능 저하**
  - ➢ Train dataset의 window 구성이 Test dataset의 window 구성과 다르기 때문
  - ➢ Train dataset, Test dataset 각각 한 일자 당 두 시점, 한 시점의 image로 구성

해상도 (480,270)	버터헤드 2-2		로메인 2-2		
	MAE	MAPE	MAE	MAPE	평균
기존 방법론	0.464	0.090	0.511	0.120	1.185
3D CNN(1)	2.030	0.248	1.337	0.179	3.794

->Test dataset과 동일한 Window 구성을 갖도록 Train dataset을 조정하자!

3. 시계열 모델링

실험 1

Train	Test
1일차 6시	1일차 12시
1일차 18시	2일차 12시
2일차 6시	3일차 12시

실험 2

Train	Test
1일차 18시	1일차 12시
2일차 18시	2일차 12시
3일차 18시	3일차 12시

4. 시계열 모델링 실험 결과

❖ 실험2. 학습 data 절반 사용

- 학습 data를 모두 사용했을 때보단 성능 개선, but 기존 방법론보다 여전히 성능 저하
  - ➢ Test data와 동일한 window 구성으로 학습을 진행하였기에 성능이 개선되었음
  - ➢ 그러나 **학습 data가 99(로메인)/117(버터헤드)**개로 더 적어졌기에 충분한 학습이 되지 않아 기존 방법론보다 성능이 저하됨

해상도 (480,270)	버터헤드 2-2		로메인 2-2		
	MAE	MAPE	MAE	MAPE	평균
기존 방법론	0.464	0.090	0.511	0.120	0.296
3D CNN(1)	2.030	0.248	1.337	0.179	0.949
3D CNN(2)	0.885	0.112	0.734	0.104	0.459

4. 시계열 모델링 실험 결과

❖ 로메인 2차 재배 2판 실험 결과

- True Label(일자)별 Difference 시각화

비슷한 양상을 띄나
True Label 11의 경우 예측 성능이 크게 저하된다는 문제점

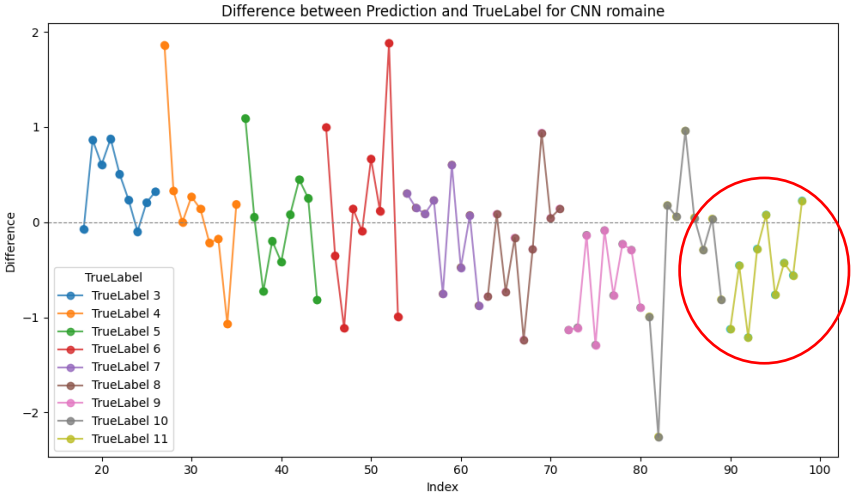

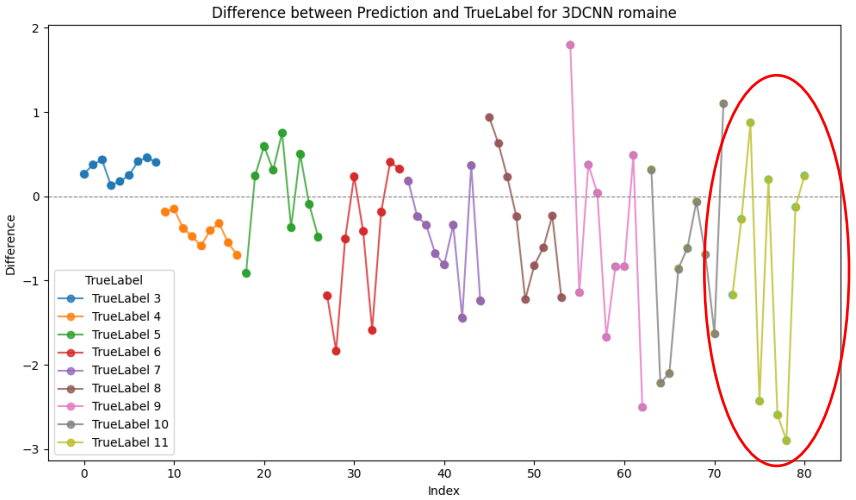

4. 시계열 모델링 실험 결과

❖ 로메인 2차 재배 2판 실험 결과

- True Label(일자)별 Mean Difference 시각화

3D CNN이 기존 모델보다
대부분 Mean difference 값이 더 작음
->True label보다 더 작게 예측하는 경향이 커짐
Q. 3DCNN 모델의 문제인가?

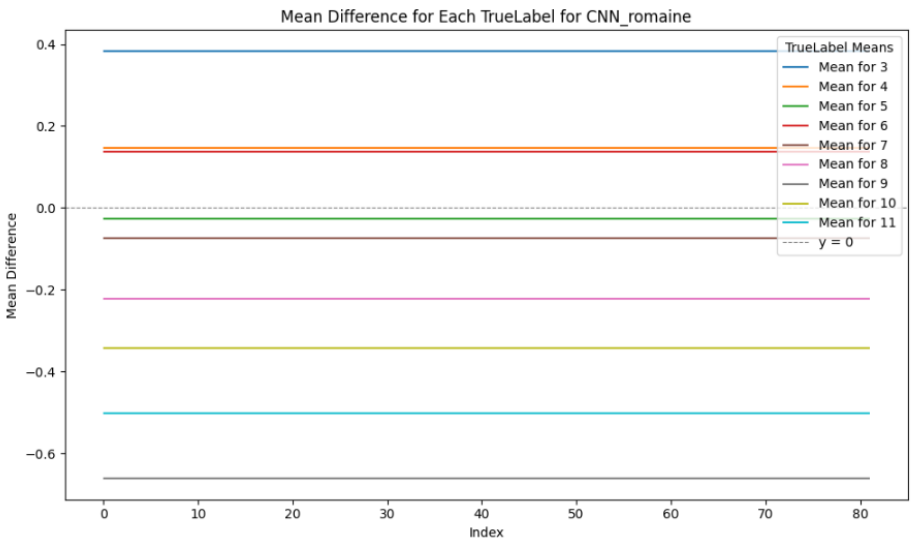

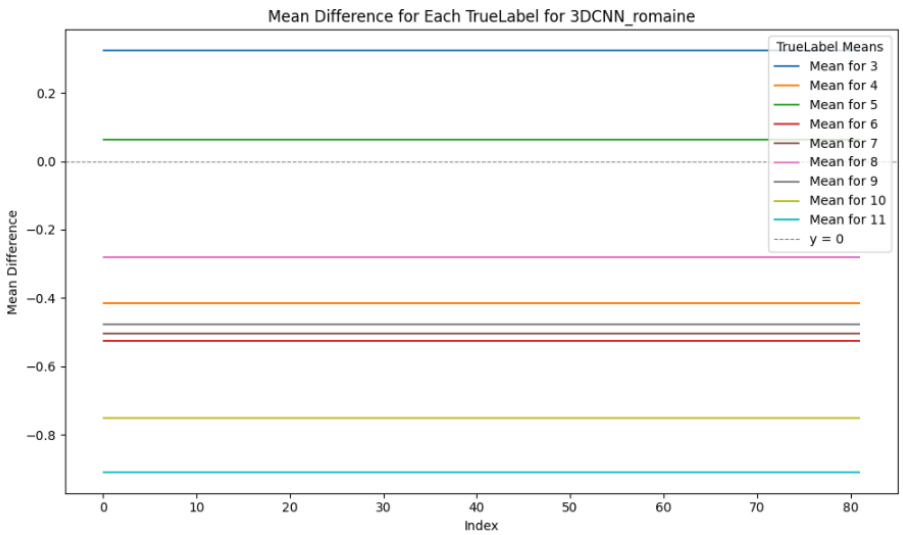

4. 시계열 모델링 실험 결과

❖ 로메인 2차 재배 2판 실험 결과

- Plant number별 예측 값 시각화

모든 작물에 대해 prediction 값이
지속적으로 감소하는
경향은 살펴볼 수 없었음
<u>선형적으로 증가하는 형태</u>
A. 3D CNN 모델 자체의 문제는 아니라고 판단
->데이터의 한계(학습 데이터 수 부족, 가려짐 현상)

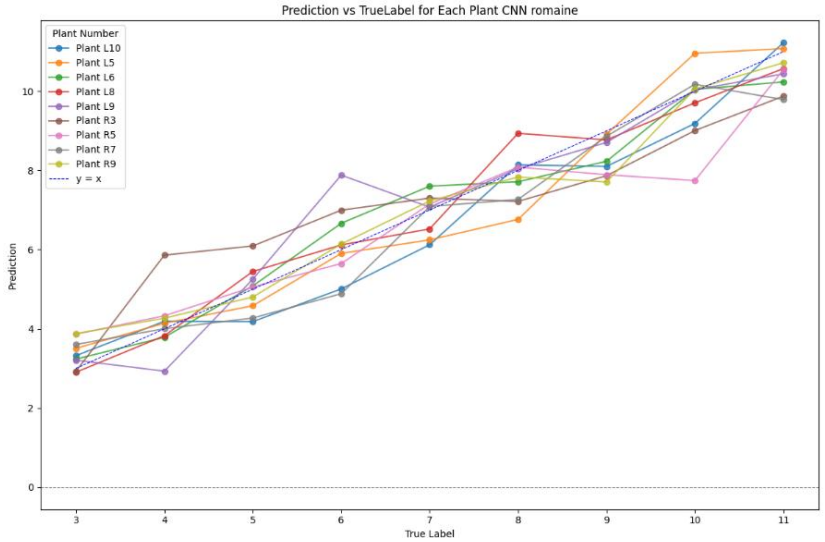

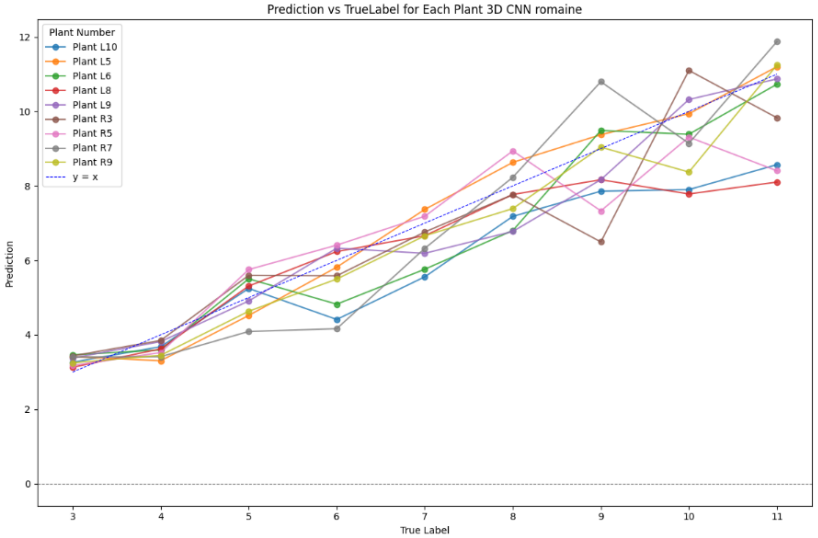

4. 시계열 모델링 실험 결과

❖ 버터헤드 2차 재배 2판 실험 결과

- True label(일자)별 Difference 시각화

비슷한 양상을 띄나
True Label 13의 경우 예측 성능이 크게 저하된다는 문제점
(Label number가 커질수록 성능 저하 현상 두드러짐)

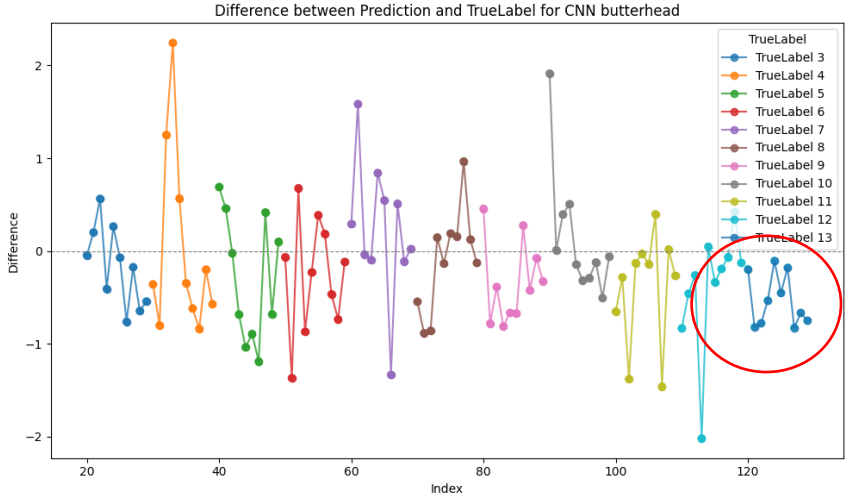

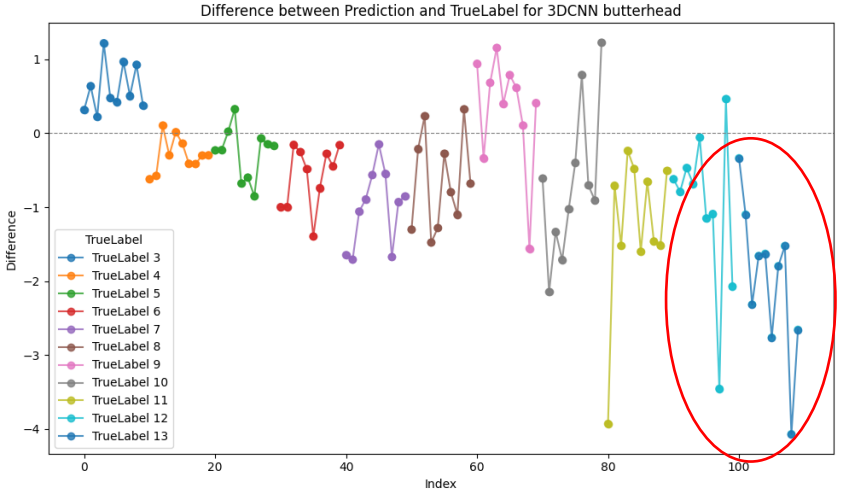

4. 시계열 모델링 실험 결과

❖ 버터헤드 2차 재배 2판 실험 결과

- True Label(일자)별 Mean Difference 시각화

마찬가지로 3D CNN이 기존 모델보다
대부분 Mean difference 값이 더 작음
->True label보다 더 작게 예측하는 경향이 커짐
3DCNN 모델 자체의 문제는 아닐 것이라 판단

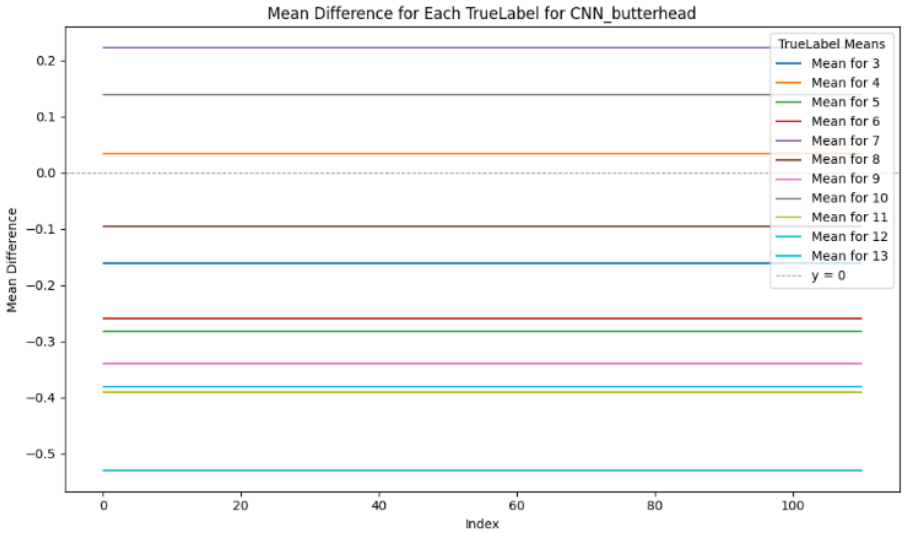

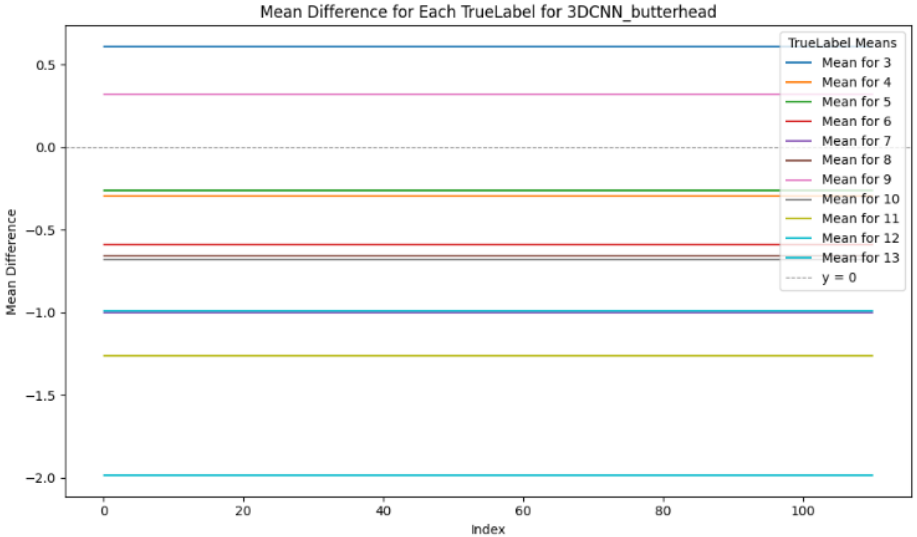

4. 시계열 모델링 실험 결과

❖ 버터헤드 2차 재배 2판 실험 결과

- Plant number별 Prediction 시각화

모든 작물에 대해 prediction 값이
지속적으로 감소하는
경향은 살펴볼 수 없었음
<u>선형적으로 증가하는 형태</u>
->그러나 R5 작물에 대한 관찰 필요할 것이라 판단

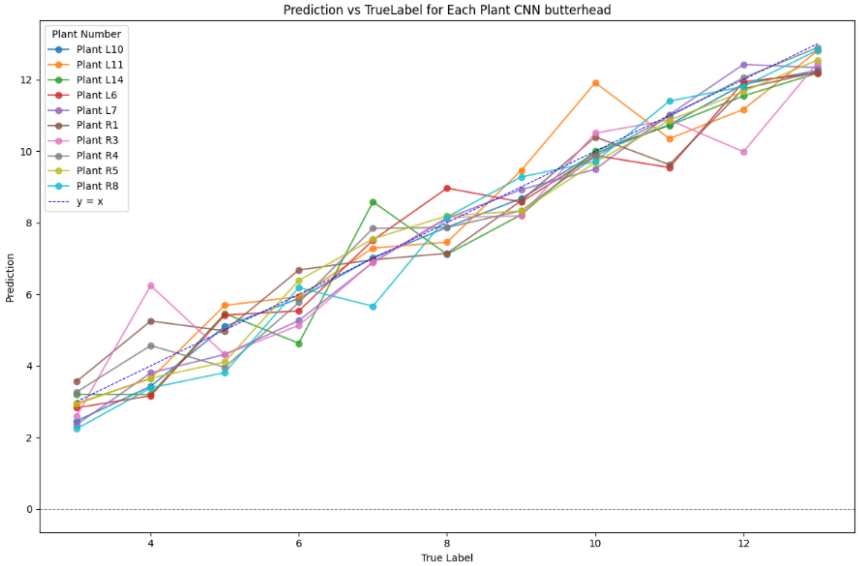

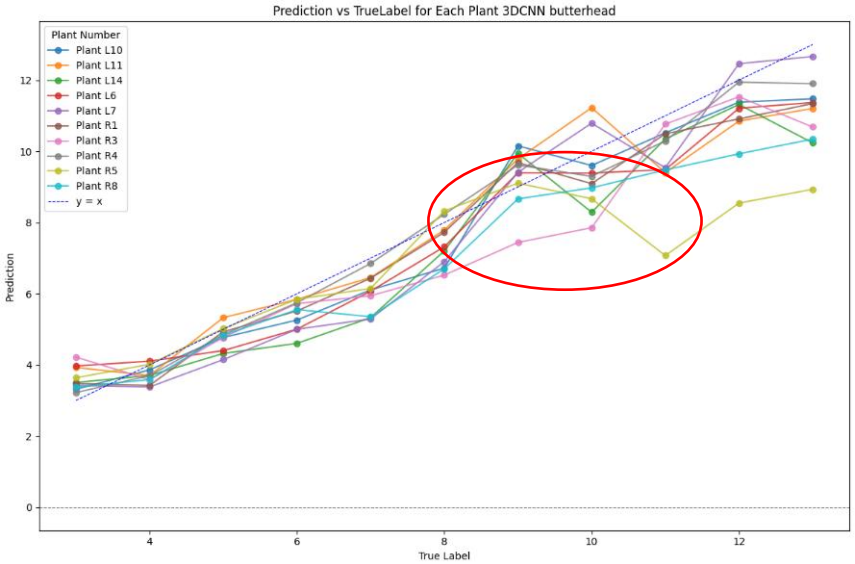

4. 시계열 모델링 실험 결과

❖ 버터헤드 2차 재배 2판 실험 결과

- R5 작물

일자별 작물의 크기가
증가할 것이라는 예상과는 다르게
가려진 작물의 사진이 input으로 들어간 것을 확인
->데이터의 한계(가려짐 현상)

240625_12

240626_12

240627_12

5. 결론

❖ Uncertainty

- **결론: Dropout rate가 올라갈수록 Uncertainty 증가, MAE 감소**

❖ 3D CNN vs 2D CNN

- **결론: 기존 방법론(2D CNN)보다 3D CNN의 성능 저하**
- **원인 분석**
  - ➢ **학습 데이터 수 부족**

    2D CNN보다 학습 데이터 수 절반 감소
  - ➢ **학습 데이터 변형**

    가려진 작물 image가 학습 data로 사용됨
  - ➢ **학습 데이터 1개가 아닌 3개가 input으로 사용**

    작물이 가려지는 경향을 학습하여 mean difference가 전반적으로 낮게 나옴

6. 인턴생활 후기

❖ 인턴생활 느낀 점, 배운 점

Data Mining
Quality Analytics