정기미팅

<생육 분석 자동화 Vision AI 모델 개발>

SAM 세그멘테이션

2024. 12. 26

Korea University

Data **M**ining & **Q**uality **A**nalytics Lab.

목차

- 인턴 생활 로드맵
- 1. 연구 계획
- 2. 세그멘테이션 모델 선택 (SAM)
- 3. SAM 모델 성능 분석
- 4. SAM2 모델과 비교
- 5. SAM fine-tuning
- 6. 결론
- 7. 인턴 생활 후기

인턴 생활 로드맵

❖ 생육일자 예측을 위한 세그멘테이션

- 작물 데이터셋 라벨링
- 세그멘테이션을 위한 모델 선택 (SAM)
- 세그멘테이션 성능 개선 노력 (다양한 프롬프트, SAM2 비디오 트래킹, fine-tuning)

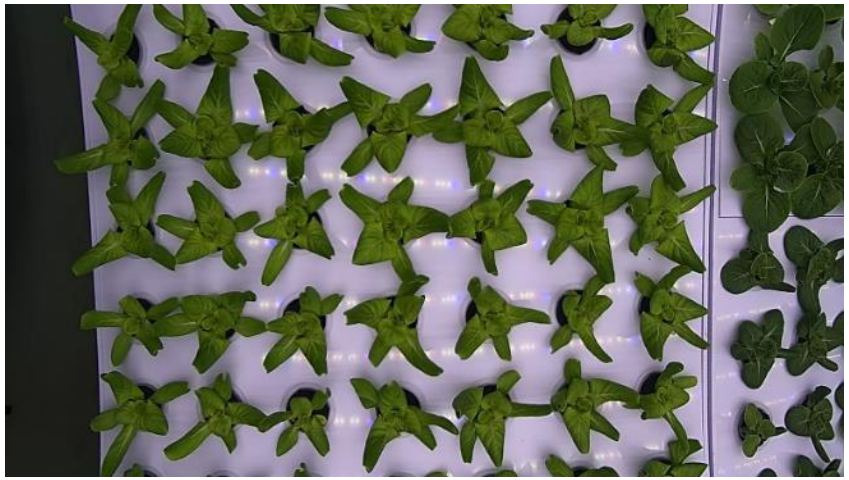

[입력 이미지]

[SAM 예측]

인턴 생활 로드맵

❖ 생육일자 예측

- 작물 세그멘테이션 결과로, 개별 작물 생육일자 예측
- Resnet 모델 활용
- 예측 성능 개선 노력 (2D Resnet, 3D Resnet (sequential data), 모델 복잡도 조정)

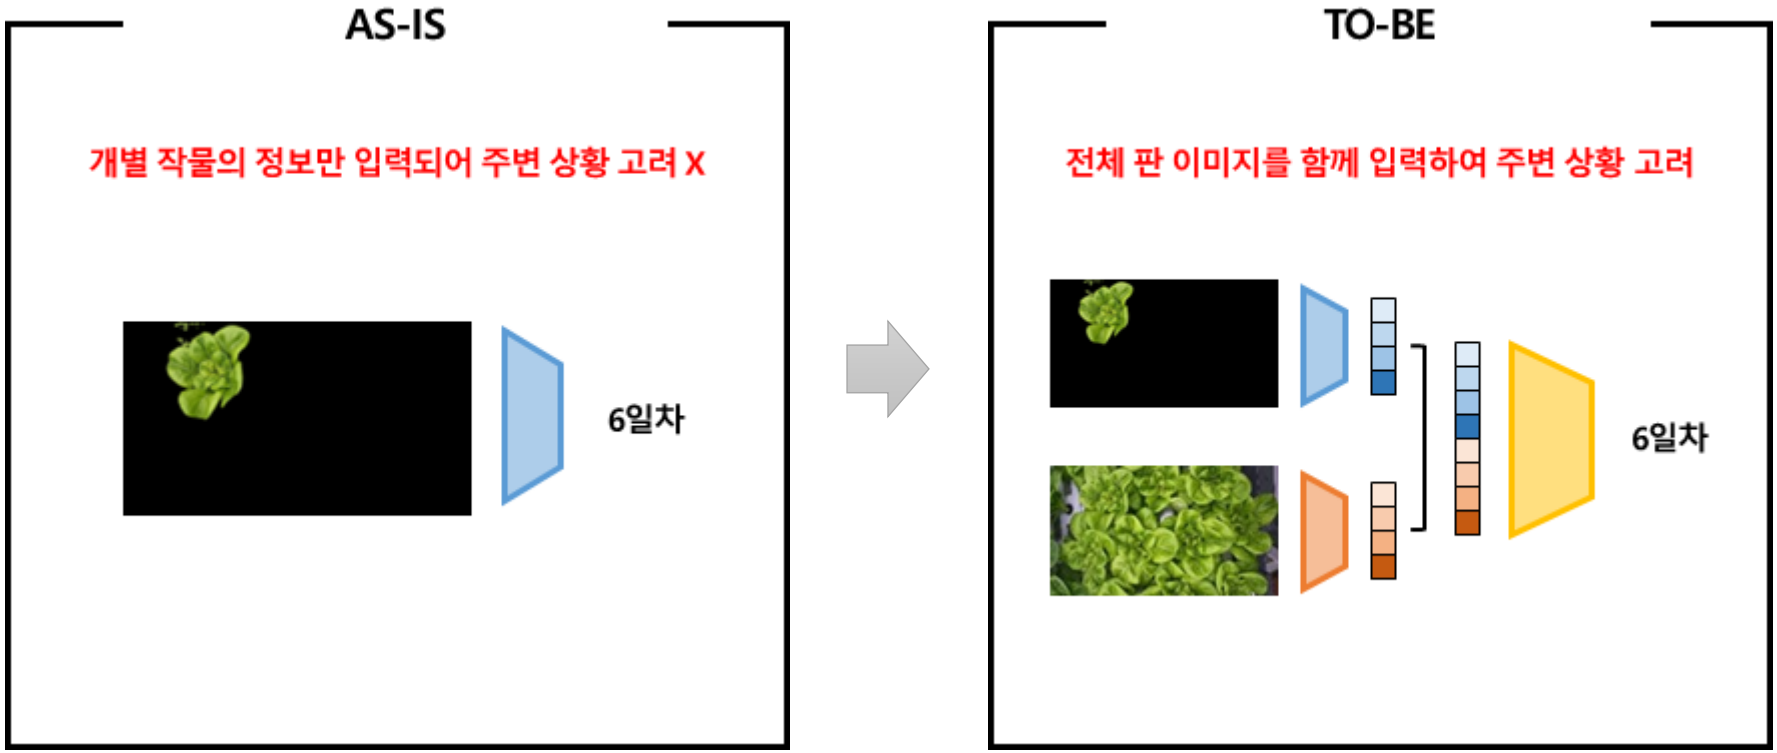

1. 연구 계획

❖ 세그멘테이션을 위한 논문 리뷰

- Mask R-CNN

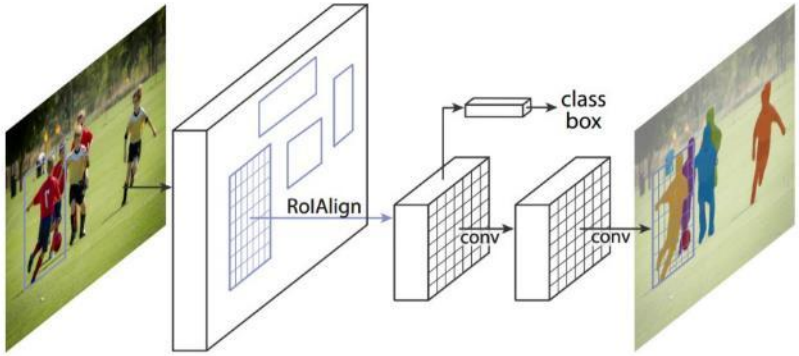

- SOLO (Segmenting Objects by Locations)

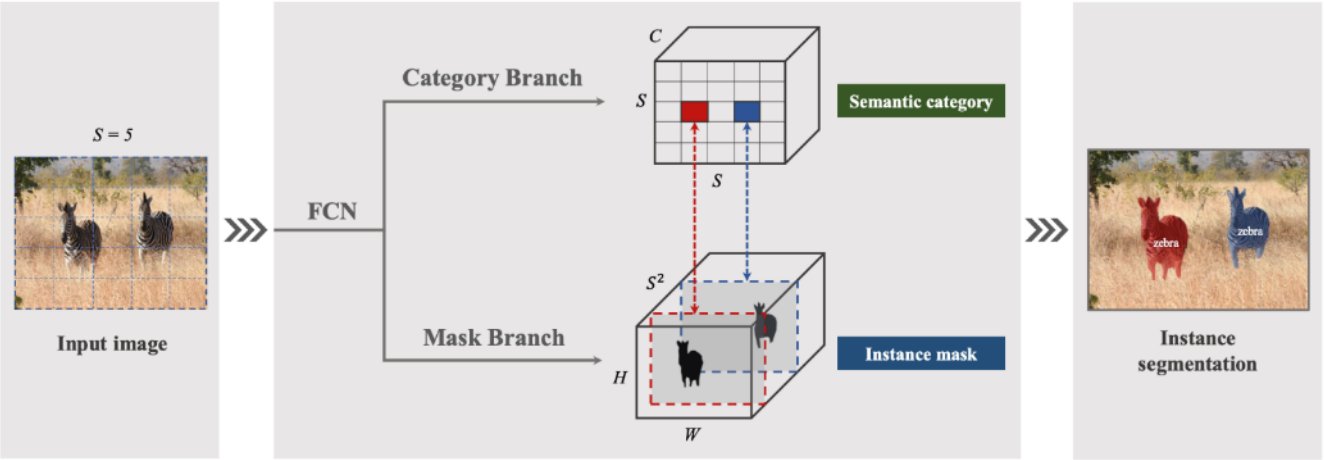

1. 연구 계획

❖ 세그멘테이션을 위한 논문 리뷰

- DeepLabV3+

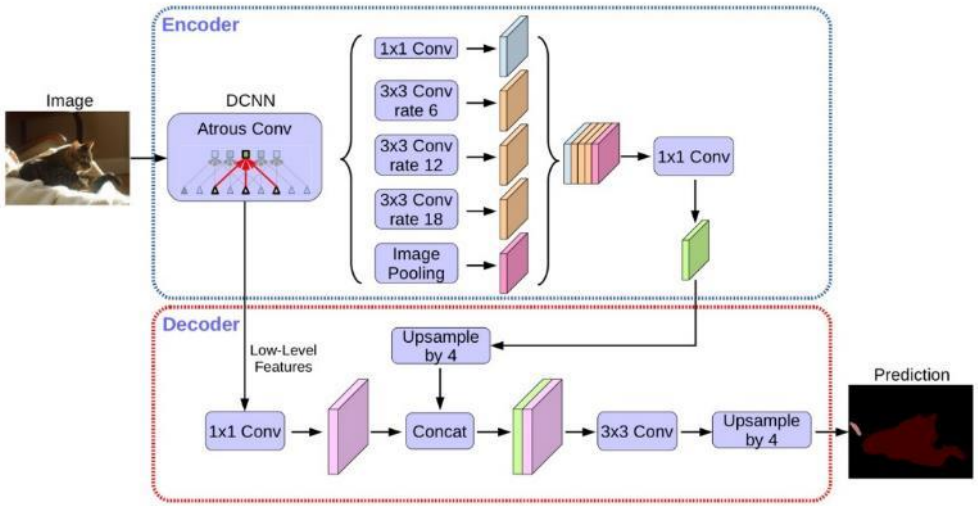

- SAM (Segment Anything Model)

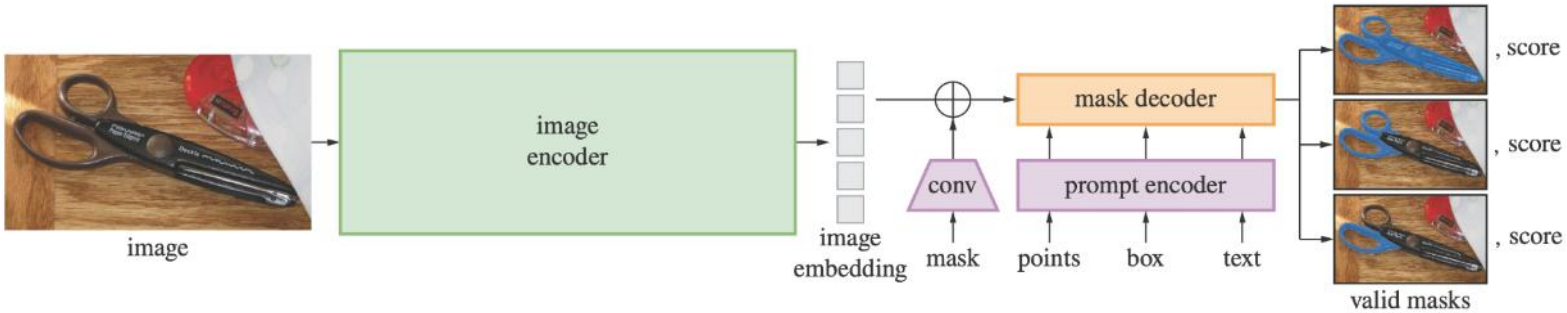

2. 세그멘테이션 모델 선택 (SAM)

❖ 세그멘테이션 모델로 SAM 선택

- 데이터셋이 적은 상태
  - SAM은 대규모 데이터로 pre-train된 모델, 따라서 학습할 필요 X
- Prompt(점, 박스, 마스크)를 기반으로, 인스턴스 세그멘테이션 가능

3. SAM 성능 분석

❖ **라벨(정답) 사용하여, 이미지 세그멘테이션**

- 정답 마스크를 보고, 프롬프트 생성 (점, 박스)

3. SAM 성능 분석

❖ **라벨(정답) 사용하여, 이미지 세그멘테이션**

- 박스 + 점을 사용했을 때, 가장 성능이 좋다.

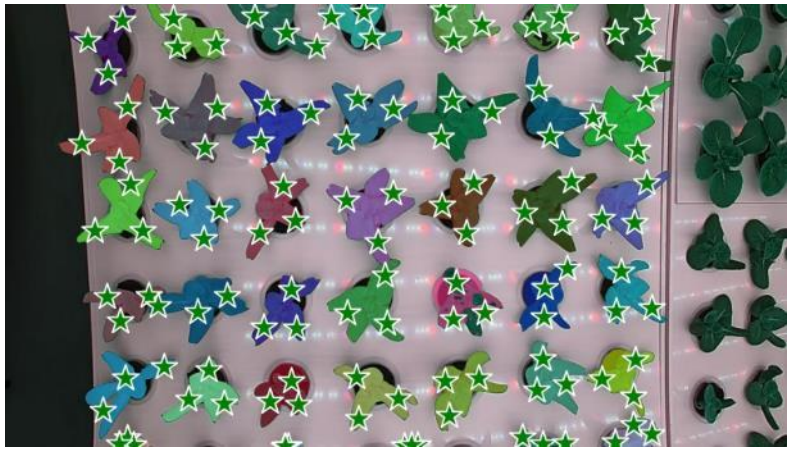

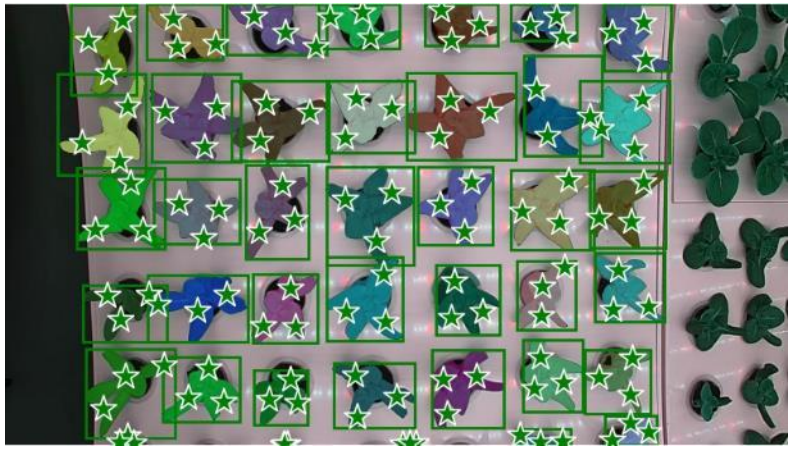

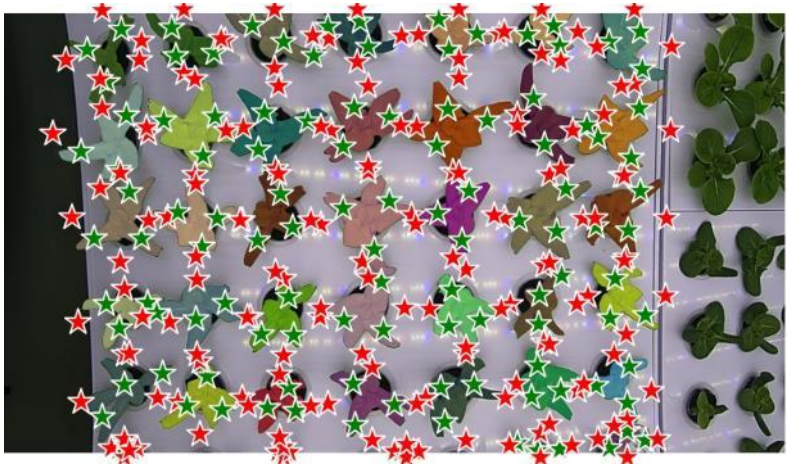

3. SAM 성능 분석

❖ 라벨(정답) 사용하여, 이미지 세그멘테이션

- 박스 + 점을 사용했을 때, 가장 성능이 좋다.

Butterhead	AP50	AP75	APsmall	APmedium	APlarge
점	0.704959	0.309312	0.001701	0.011558	0.732422
박스	0.88764	0.383591	0.027592	0.043653	0.824488
점+박스	0.921489	0.414301	0.021989	0.038897	0.870142
점+빨간점	0.676293	0.252195	0.005796	0.016521	0.673252

redlettuce	AP50	AP75	APsmall	APmedium	APlarge
점	0.290747	0.121895	0.000000	0.025765	0.271105
박스	0.972543	0.591788	0.016919	0.097047	0.864087
점+박스	0.942963	0.528187	0.012143	0.084362	0.854152
점+빨간점	0.409961	0.267071	0.000000	0.038399	0.376578

romaine	AP50	AP75	APsmall	APmedium	APlarge
점	0.710982	0.243042	0.000000	0.046215	0.669045
박스	0.935401	0.606977	0.002144	0.072249	0.864144
점+박스	0.940741	0.560526	0.001385	0.064594	0.878097
점+빨간점	0.466973	0.092947	0.000938	0.014560	0.454605

3. SAM 성능 분석

❖ 라벨(정답) 없이 세그멘테이션

- (가정) n번째 사진과 n+1번째 사진이 큰 차이를 보이지 않을 것
- 이전 시점의 세그멘테이션 결과로, 다음 시점의 프롬프트 생성

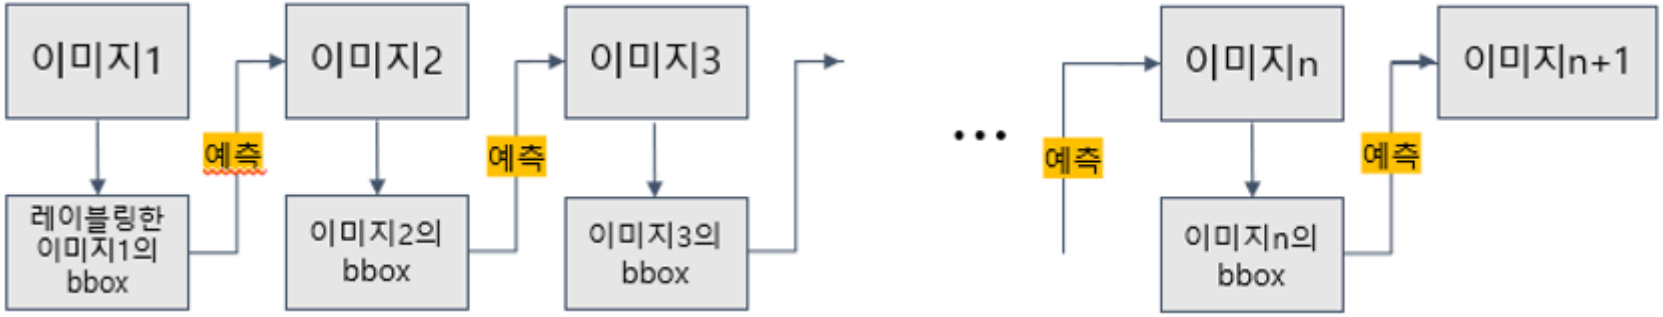

3. SAM 성능 분석

❖ 라벨(정답) 없이 세그멘테이션

- 첫 번째 시점의 바운딩 박스를, 두 번째 시점의 프롬프트로 입력
- 이때, 작물의 성장을 고려하여, 바운딩 박스의 크기에 tolerance 사용하여 확대
- 성공적인 결과

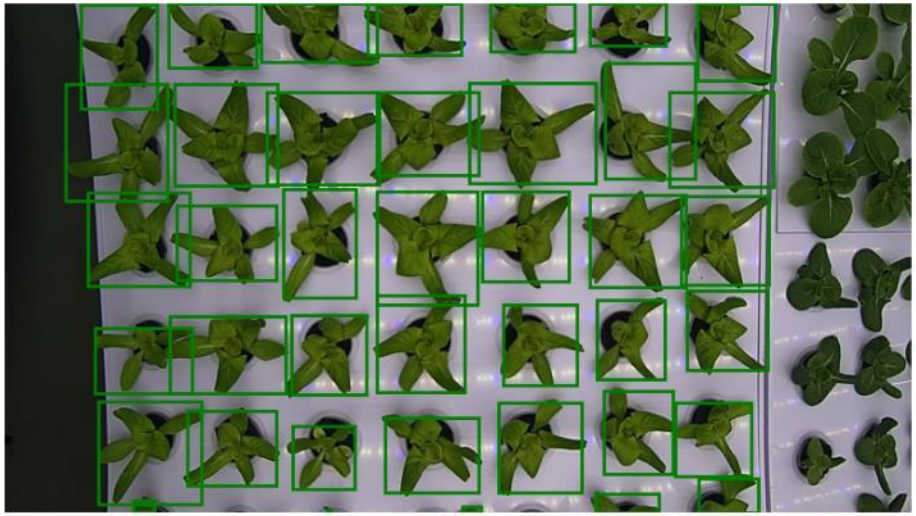

3. SAM 성능 분석

❖ 라벨(정답) 없이 세그멘테이션

- 시간이 지날수록, 세그멘테이션 성능 저하
- 카메라 시점이 변하는 경우, 급격한 성능 저하 발생

(3번째 순서) (18번째 순서) (33번째 순서)

Ground truth

Box prompt

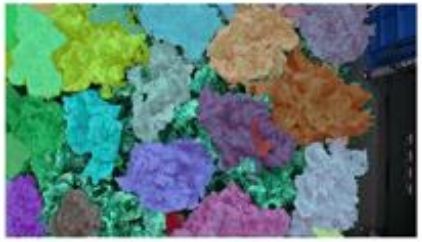

AP50	1	0.8862	0.3103
AP75	0.8464	0.3938	0.0345

4. SAM2 모델과의 비교

❖ SAM2 모델

- SAM2는 비디오 세그멘테이션 지원
- (기대) 객체 트래킹이 가능하기 때문에, SAM보다 나은 성능을 보일 것

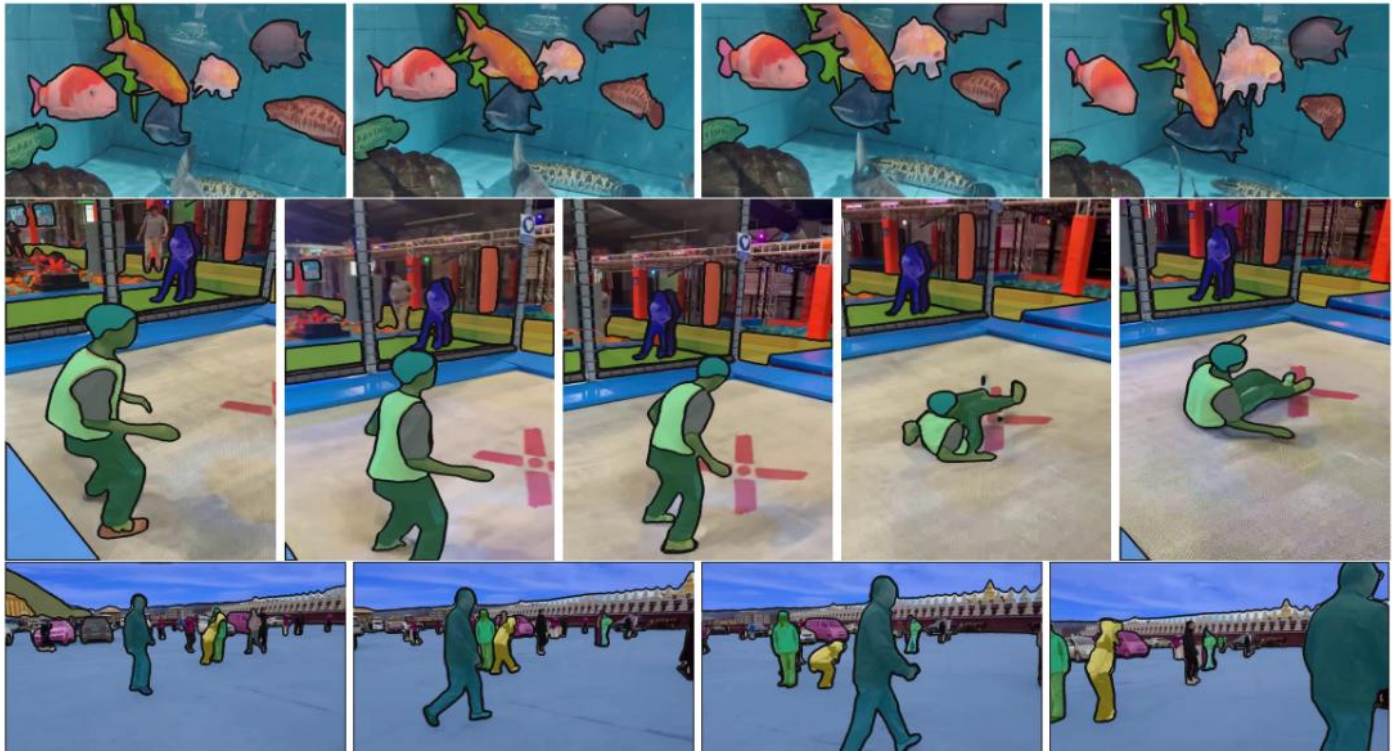

4. SAM2 모델과의 비교

❖ SAM2 모델

- 관심 객체 수가 많아질수록, 대용량 GPU 필요
- 또한, 앞의 SAM 결과보다 낮은 성능을 보임

4. SAM2 모델과의 비교

❖ SAM2 모델

- 육안으로도 기존과 뚜렷한 성능 차이를 보이며, GPU 부족 현상 발생

[SAM 이미지 세그멘테이션]

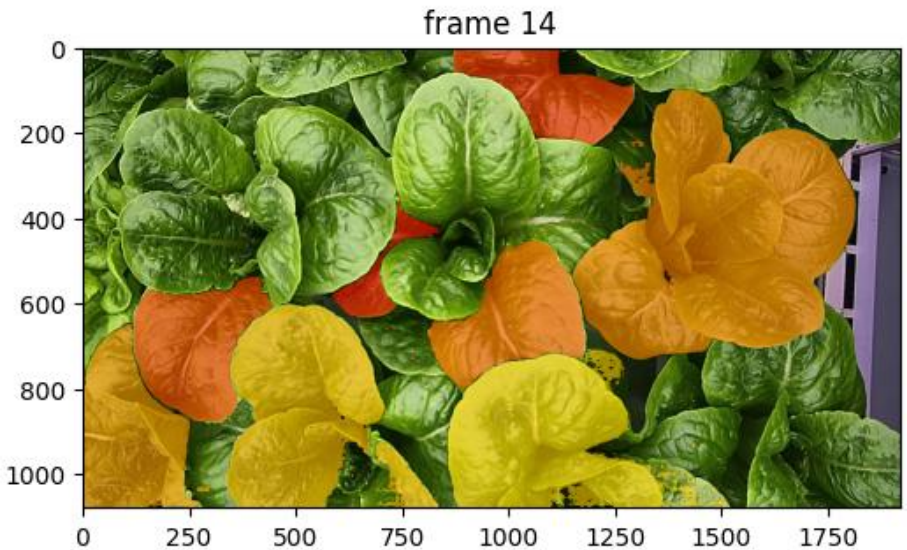

[SAM2 비디오 세그멘테이션]

4. SAM2 모델과의 비교

❖ 성능 저하의 원인 추정

- SAM2 논문의 Limitations
  - 혼잡한 장면, 가려짐에서 object를 추적하지 못하거나 혼동
  - 미세한 디테일이 있는 object를 정확하게 추적하는 데 어려움
  - 비슷한 모양의 object가 근처에 있는 경우 어려움
- 우리의 데이터셋이 위의 설명과 일치
- 또한, SAM2는 비디오 세그멘테이션을 위해, 모델 크기를 경량화 (약 1/3배)

[작물 데이터셋]

5. SAM fine-tuning

❖ SAM의 문제

- 복잡한 작물 데이터셋에서 세그멘테이션 성능 저하
- 따라서, SAM을 fine-tuning하여 SAM의 작물 세그멘테이션 성능을 올리고자 함.

- 이때, 상대적으로 경량화된 Decoder를 fine-tuning
- Fine-tuning 입력 : prompt와 ground truth

5. SAM fine-tuning

❖ Fine-tuning 결과

- Fine-tuning 결과, 성능이 저하
- 여러 테스트 결과, Loss도 유의미하게 줄지 않음.

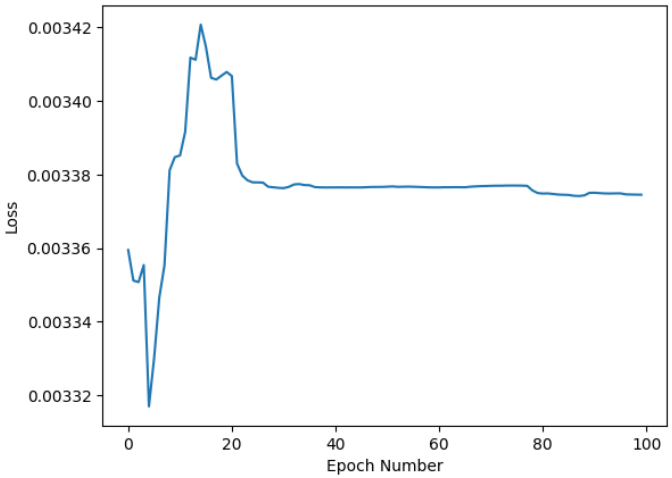

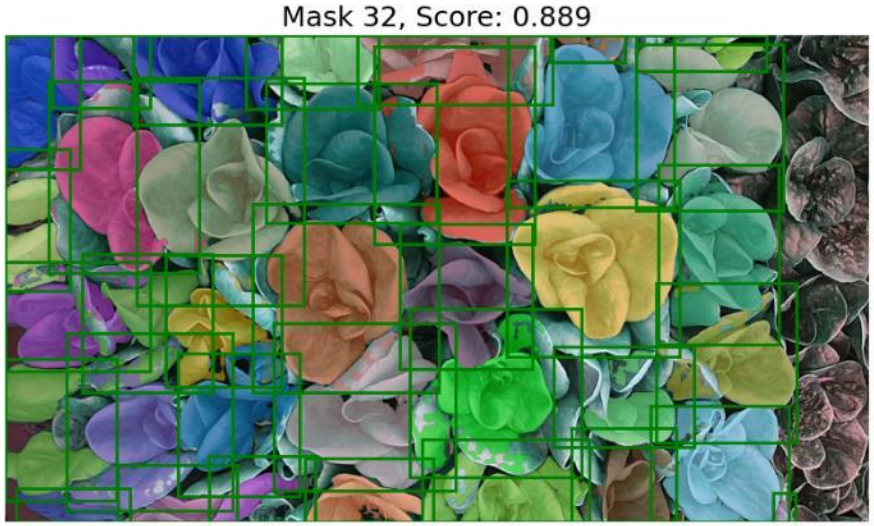

[기존 SAM]

[Fine-tuning 결과]

5. SAM fine-tuning

❖ 성능 저하 원인 분석

- 여러 SAM fine-tuning 논문 분석
- SAM 모델이 대용량 모델이기 때문에, LORA 활용
- CAT-SAM과 같은 fine-tuning 논문들을 보았을 때, batch size 16으로 설정하기 위해 NVIDIA RTX A6000 4개 (48GB X 4) 사용

- 이때, SAM은 decoder가 경량화된 비대칭 구조
- 따라서, GPU 환경을 고려하여 디코더만 fine-tuning
- 여러 논문 확인 결과, Decoder만 fine-tuning하는 것은 큰 효과가 없음.

$$\mathrm{DSC} = \frac{2|A \cap B|}{|A| + |B|}$$

Table 2: Ablation study on finetuning method of SAMed (The embedding in prompt encoder is finetuned by default).

Methods	DSC↑	Aorta	Gallbladder	Kidney(L)	Kidney(R)	Liver	Pancreas	Spleen	Stomach
Mask decoder	67.95	79.94	39.49	76.72	73.55	90.87	44.15	73.79	65.11
Image encoder + mask decoder	**81.88**	**87.77**	**69.11**	**80.45**	**79.95**	**94.80**	**72.17**	**88.72**	**82.06**

5. SAM fine-tuning

❖ 성능 저하 원인 분석

- 디코더 fine-tuning이 효과가 없는 이유 (추정)
  - SAM의 구조에서 인코더는 이미지에서 feature를 추출하는 역할
  - 즉, 특정 작물 이미지의 feature를 학습하기 위해서, 인코더 학습이 필요

- 인코더를 fine-tuning 한다면 성능 개선이 될까?
  - ViT 논문 – 비전 트랜스포머(ViT) 기반 인코더는 고차원 표현을 다루기 때문에, 충분한 데이터가 없으면 학습이 불안정

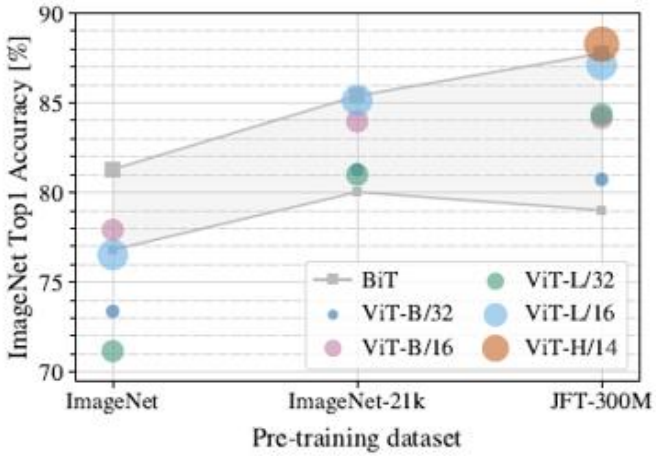

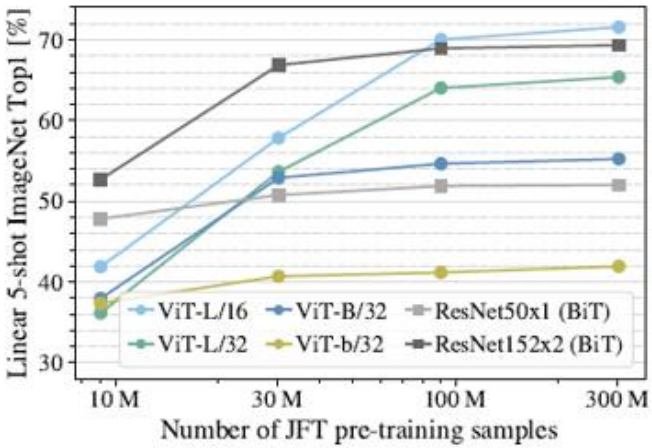

6. 결론

❖ 세그멘테이션 모델로 SAM 선택

- 복잡한 작물 데이터셋에서, 프롬프트로 인스턴스 세그멘테이션 가능
- 이때, 이전 시점의 세그멘테이션 결과로, 다음 시점의 프롬프트 생성
- 기존 실험 대비, 뛰어난 성능을 보임.

❖ SAM의 작물 세그멘테이션 성능 개선 노력

- SAM2의 비디오 트래킹 -> 복잡한 데이터셋, 더 경량화된 모델 -> 성능 저하
- SAM fine-tuning -> GPU 환경으로 인해 디코더만 fine-tuning -> 성능 저하

6. 결론

❖ 최종 세그멘테이션 모델

- 이전 시점의 결과로 바운딩 박스 + 점을 생성, 이를 활용하여 다음 시점 세그멘테이션
- 이때, 작물 성장을 고려한 bounding box 크기 조절

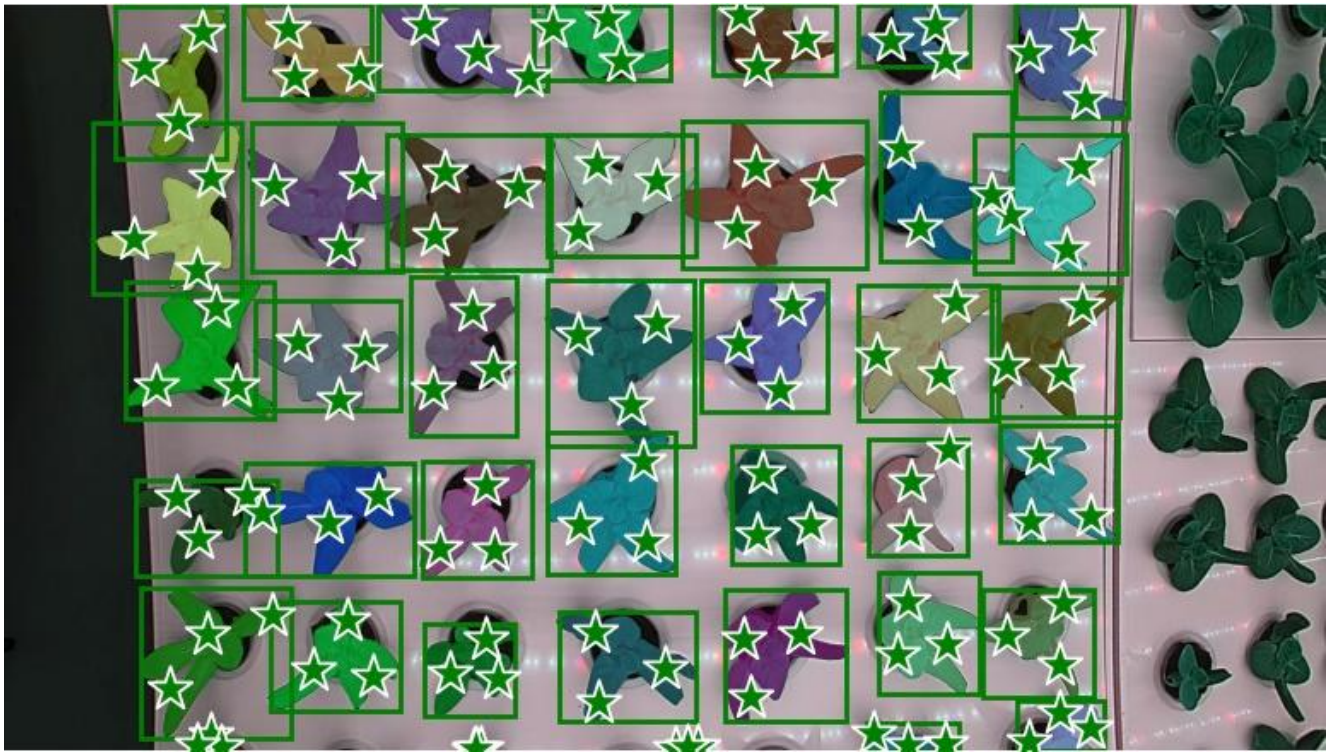

6. 결론

❖ 세그멘테이션 모델 제안

- 많은 모델 중, SAM을 선택한 가장 큰 이유 = 프롬프트
- ViT 기반 모델의 단점 – 데이터셋의 크기가 클 때, 성능이 좋다. -> 학습이 어렵다.

- 작은 데이터셋에서는 ViT보다 CNN이 높은 성능을 보임.
- SAM의 이미지 인코더를 CNN 기반 모델(Deeplab, Resnet 등)로 교체
- 기존 SAM과 다르게, 작물 이미지 학습이 가능하므로 높은 성능 기대

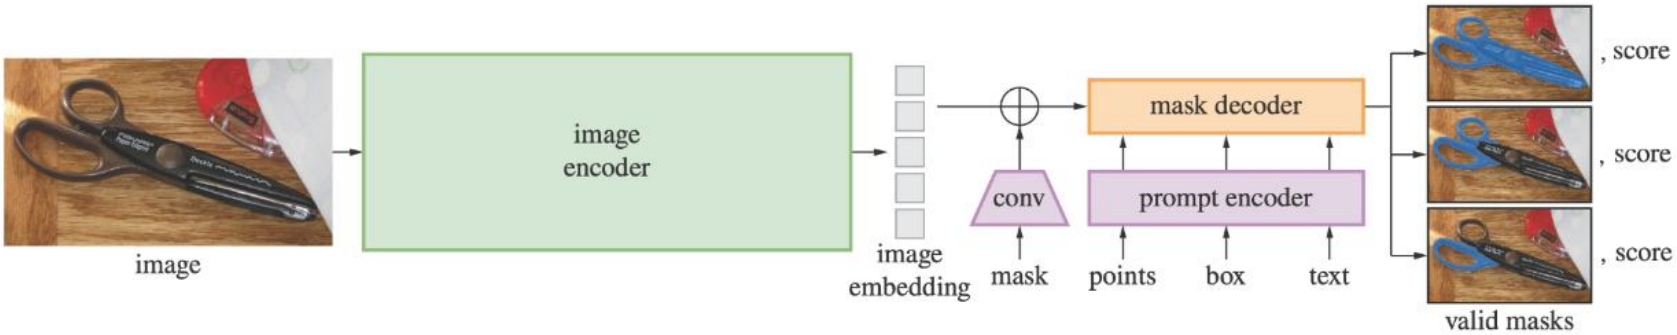

7. 인턴 생활 후기

❖ 인턴 생활 느낀 점, 배운 점